

Gradient a smerová derivácia

Maksym Kryhul

22.05.2026

Obsah

1 Úvod	1
2 Teoretické pozadie	2
2.1 Parciálne derivácie	2
2.2 Gradient	2
2.3 Smerová derivácia	3
3 Výpočty	3
3.1 Úloha 1: Gradient funkcie	3
3.2 Úloha 2: Smerová derivácia	4
4 Vizualizácia	5
4.1 3D Graf funkcie	5
4.2 Porovnanie normy gradientu v rôznych bodoch	7
5 Záver	9
Literatúra	9

1 Úvod

Gradient je vektor, ktorý v každom bode priestoru ukazuje smer najrýchlejšieho rastu danej skalárnej funkcie, pričom jeho veľkosť určuje rýchlosť tohto rastu. Z hľadiska geometrického významu je vektor gradientu vždy kolmý na vrstevnice (alebo ekvipotenciálne plochy) danej funkcie. Gradient patrí medzi kľúčové pojmy matematickej analýzy funkcií viacerých premenných a úzko súvisí s parciálnymi deriváciami a smerovou deriváciou.

Nachádza uplatnenie v mnohých oblastiach aplikovanej matematiky, fyziky a informatiky. Napríklad v strojovom učení sa gradient využíva v algoritme gradientného zostupu na minimalizáciu účelovej funkcie. Vo fyzike gradient teplotného poľa udáva smer tepelného toku.

V tejto správe sa venujeme gradientu a smerovej derivácii funkcií viacerých premenných. Výpočty realizujeme symbolicky v jazyku Python, výsledky vizualizujeme a interpretujeme ich geometrický význam.

Ciele správy:

- vypočítať parciálne derivácie a gradient zadanej funkcie.
- určiť smerovú deriváciu v danom smere.
- vizualizovať povrch funkcie pomocou 3D grafu.
- analyzovať normu gradientu v rôznych bodoch.
- interpretovať výsledky geometricky.

2 Teoretické pozadie

Teoretické základy sú prevzaté z (Stewart 2016) a (Bacigál 2026).

2.1 Parciálne derivácie

Nech $f(x, y)$ je funkcia dvoch premenných. Parciálna derivácia funkcie f podľa premennej x je definovaná vzťahom (Rovnica 1).

$$\frac{\partial f}{\partial x} = \lim_{\Delta x \rightarrow 0} \frac{f(x + \Delta x, y) - f(x, y)}{\Delta x} \quad (1)$$

Analogicky definujeme parciálnu deriváciu podľa y .

2.2 Gradient

Gradient funkcie $f(x, y)$ je vektorová funkcia definovaná vzťahom (Rovnica 2). Gradient ukazuje smer **najrýchlejšieho rastu** funkcie v danom bode.

$$\nabla f(x, y) = \left(\frac{\partial f}{\partial x}, \frac{\partial f}{\partial y} \right) \quad (2)$$

2.3 Smerová derivácia

Smerová derivácia funkcie f v bode B v smere vektora $\vec{v}$ je definovaná vzťahom (Rovnica 3).

$$D_{\vec{v}}f = \nabla f \cdot \frac{\vec{v}}{|\vec{v}|} \quad (3)$$

kde ∇f je gradient funkcie v danom bode a $\frac{\vec{v}}{|\vec{v}|}$ je jednotkový vektor smeru. Smerová derivácia udáva rýchlosť zmeny funkcie v smere vektora $\vec{v}$.

3 Výpočty

V tejto správe používame knižnicu `sympy` (Team 2023) — knižnicu pre symbolickú matematiku v jazyku Python, `numpy` (Harris et al. 2020) — pre numerické výpočty na sieti bodov a `matplotlib` (Hunter 2007) — pre vizualizáciu grafov.

3.1 Úloha 1: Gradient funkcie

Vypočítame gradient funkcie $f(x, y) = \sqrt{4 + x^2 + y^2}$ a vyjadríme ho v bode $A = (1, 2)$ (Úloha 3.3a, Tomek (2026)).

```
import sympy as sp

x, y = sp.symbols('x y')

f = sp.sqrt(4 + x**2 + y**2)

df_dx = sp.diff(f, x)
df_dy = sp.diff(f, y)

#gradient
gradient = sp.Matrix([df_dx, df_dy])
print("Gradient f =", gradient)

#gradient v bode A = (1, 2)
bod_A = {x:1, y:2}
gradient_A = gradient.subs(bod_A)
print("Gradient v bode A =", gradient_A)
```

```
Gradient f = Matrix([[x/sqrt(x**2 + y**2 + 4)], [y/sqrt(x**2 + y**2 + 4)]])
Gradient v bode A = Matrix([[1/3], [2/3]])
```

Z výsledku vidíme, že gradient funkcie f v bode $A = (1, 2)$ je:

$$\nabla f(1, 2) = \left(\frac{1}{3}, \frac{2}{3} \right)$$

3.2 Úloha 2: Smerová derivácia

Vypočítame smerovú deriváciu funkcie $x^2y + xy^2$ v bode $B = (1, 2)$ v smere vektora $\vec{v} = (3, 4)$ (Úloha 3.5a, Tomek (2026)).

```
import sympy as sp

x, y = sp.symbols('x y')

f = x**2 * y + x * y**2

df_dx = sp.diff(f, x)
df_dy = sp.diff(f, y)

# gradient
gradient = sp.Matrix([df_dx, df_dy])

# bod B a vektor v

bod_B = {x:1, y:2}
v = sp.Matrix([3, 4])

#gradient v bode B
gradient_B = gradient.subs(bod_B)

# normalizovaný vektor
v_norm = v / v.norm()

# smerová derivácia
D_v = gradient_B.dot(v_norm)
D_v = sp.simplify(D_v)

print("Gradient =", gradient)
```

```
print("Gradient v bode B =", gradient_B)
print("Smerová derivácia =", D_v)
```

```
Gradient = Matrix([[2*x*y + y**2], [x**2 + 2*x*y]])
Gradient v bode B = Matrix([[8], [5]])
Smerová derivácia = 44/5
```

Z výsledku vidíme, že gradient funkcie f v bode $B = (1, 2)$ je $\nabla f(1, 2) = (8, 5)$ a smerová derivácia v smere vektora $\vec{v} = (3, 4)$ je:

$$D_{\vec{v}}f(1, 2) = \frac{44}{5} = 8,8$$

To znamená, že funkcia rastie rýchlosťou 8,8 na jednotku dĺžky v smere vektora $\vec{v} = (3, 4)$.

4 Vizualizácia

V tejto kapitole vizualizujeme funkciu $f(x, y) = x^2y + xy^2$ pomocou knižníc **numpy** (Harris et al. 2020) a **matplotlib** (Hunter 2007).

4.1 3D Graf funkcie

```
import numpy as np
import matplotlib.pyplot as plt

# vytvoríme sieť bodov

x = np.linspace(-3, 3, 50)
y = np.linspace(-3, 3, 50)
X, Y = np.meshgrid(x, y)

# funkcia
F = X**2 * Y + X * Y**2

# 3D graf
fig = plt.figure(figsize=(8,6))
ax = fig.add_subplot(111, projection = '3d')
```

```


ax.plot_surface(X, Y, F, cmap='rainbow', alpha = 0.85)

ax.set_xlabel('x')
ax.set_ylabel('y')
ax.set_zlabel('f(x, y)')
ax.set_title('Graf funkcje f(x, y) = x2y + xy2')

plt.tight_layout()
plt.show()

```

Graf funkcje $f(x, y) = x^2y + xy^2$



Graf zobrazuje povrch funkcie $f(x, y) = x^2y + xy^2$. Červená farba zodpovedá vysokým hodnotám funkcie, modrá nízkym hodnotám.

4.2 Porovnanie normy gradientu v rôznych bodoch

```
import numpy as np
import matplotlib.pyplot as plt
import sympy as sp

x, y = sp.symbols('x y')


f = x**2 * y + x * y**2
df_dx = sp.diff(f, x)
df_dy = sp.diff(f, y)

body = [(0, 0), (1, 1), (1, 2), (2, 1), (-1, 2), (2, 2), (-2, -1)]
normy = []

for (bx, by) in body:
    gx = float(df_dx.subs({x: bx, y: by}))
    gy = float(df_dy.subs({x: bx, y: by}))
    normy.append(round((gx**2 + gy**2)**0.5, 3))

nazvy = [f'({bx},{by})' for (bx, by) in body]
farby = ['red' if n > 7 else 'blue' for n in normy]

fig, ax = plt.subplots(figsize=(8, 5))
ax.bar(nazvy, normy, color=farby)
ax.set_xlabel('Bod (x, y)')
ax.set_ylabel('Norma gradientu |f|')
ax.set_title('Porovnanie normy gradientu v rôznych bodoch funkcie  $x^2y + xy^2$ ')
ax.axhline(y=7, color='gray', linestyle='--', label='hranica rýchleho rastu')
ax.legend()
plt.tight_layout()
plt.show()
```



Z grafu vidíme, že norma gradientu sa výrazne líši v závislosti od polohy bodu. V bode (2, 2) je norma gradientu najväčšia ($|\nabla f| \approx 16.97$), čo znamená, že funkcia sa v tomto bode mení najrýchlejšie. Naopak, v bode (0, 0) je norma gradientu nulová — ide o stacionárny bod, kde funkcia nemá žiadny smer najrýchlejšieho rastu.

Červené stĺpce označujú body s rýchlym rastom ($|\nabla f| > 7$), modré stĺpce body s pomalším rastom.

Výsledky výpočtov som zhrnul v Tabuľka 1.

Tabuľka 1: Hodnoty gradientu funkcie $f(x, y) = x^2y + xy^2$ v rôznych bodoch

Bod (x, y)	$\partial f / \partial x$	$\partial f / \partial y$	$ \nabla f $
(0, 0)	0	0	0
(1, 1)	3	3	4.243
(1, 2)	8	5	9.434
(2, 1)	5	8	9.434
(-1, 2)	0	-3	3.000
(2, 2)	12	12	16.971
(-2, -1)	5	8	9.434

5 Záver

V tejto správe sme sa venovali gradientu a smerovej derivácii funkcií viacerých premenných.

Hlavné výsledky:

- Vypočítali sme gradient funkcie $f(x, y) = \sqrt{4 + x^2 + y^2}$ a vyjadrili ho v bode $A = (1, 2)$:

$$\nabla f(1, 2) = \left(\frac{1}{3}, \frac{2}{3} \right)$$

- Vypočítali sme smerovú deriváciu funkcie $f(x, y) = x^2y + xy^2$ v bode $B = (1, 2)$ v smere vektora $\vec{v} = (3, 4)$:

$$D_{\vec{v}}f(1, 2) = \frac{44}{5}$$

- Vizualizovali sme povrch funkcie pomocou 3D grafu.
- Vizualizovali sme porovnanie normy gradientu $|\nabla f|$ v rôznych bodoch pomocou stĺpcového grafu.

Gradient je základným nástrojom matematickej analýzy. Ukazuje smer najrýchlejšieho rastu funkcie — podobne ako najkratšia cesta na vrchol hory. Nachádza uplatnenie v optimalizácii, fyzike aj strojovom učení.

Literatúra

Bacigál, Tomáš. 2026. *Úvod do analýzy údajov pomocou R*. Spektrum STU. <https://tomas-bacigal.quarto.pub/uvod-do-analyzy-udajov-pomocou-r/>.

Harris, Charles R. et al. 2020. *NumPy: Array computing for Python*. <https://numpy.org>.

Hunter, John D. 2007. *Matplotlib: A 2D graphics environment*. <https://matplotlib.org>.

Stewart, James. 2016. *Calculus: Early Transcendentals*. 8th vyd. Cengage Learning.

Team, SymPy Development. 2023. *SymPy: Python library for symbolic mathematics*. <https://www.sympy.org>.

Tomek, Lukáš. 2026. *Matematická analýza 2 — cvičenia*. <https://sites.google.com/site/lukastomekmath/vyucba/matematick-analza-2>.